

Predicción del Riesgo Crediticio en la Banca mediante Machine Learning Explicable

Aplicación al caso Home Credit Default Risk

Autor: Izan Moya Romero

Máster en Inteligencia Artificial y Big Data

Fecha: Mayo 2026

Curso académico: 2025/2026

ÍNDICE

1. Resumen	4
2. Introducción	4
2.1- Motivación	4
2.2 - Objetivos	4
2.3 - Tecnologías y herramientas utilizadas	5
3. Marco Teórico	7
3.1 - El riesgo crediticio en la banca moderna	7
3.2 - Análisis exploratorio de datos (EDA)	8
3.3 - Desequilibrio de clases y técnicas de tratamiento	9
3.4 - Ingeniería de características (Feature Engineering)	10
3.5 - Modelos de clasificación supervisada	11
3.5.1 Random Forest(Bosques Aleatorios) - Familia: Bagging	11
3.5.2 LightGBM(Light Gradient Boosting Machine) - Familia:Gradient Boosting	11
3.5.3 SVM(Support Vector Machines) - Familia: Modelos geométricos	12
3.5.4 Multilayer Perceptron(MLP) - Red Neuronal Artificial - Familia:Deep Learning	12
3.6 - Explicabilidad del modelo: XAI y SHAP	12
3.7 - Despliegue con Hugging Face	13
4. Capítulo 1: Contexto y descripción del dataset	14
4.1 - Contextualización del problema	14
4.2 - Marco normativo bancario	15
4.2.1 Acuerdos de Basilea (III y IV)	15
4.2.2 GDPR (Reglamento General de Protección de Datos, UE 2016/679)	15
4.2.3 EU AI Act (Reglamento UE 2024/1689)	16
4.3 - Fuentes de datos	16
4.3.1 Origen del dataset	16
4.3.2 Decisión metodológica: enfoque Lean sobre una sola tabla	17
4.3.3 Fichero complementario	17
4.4 -Estructura y lectura del dataset	18
4.4.1 Dimensiones del dataset	18
4.4.2 La variable objetivo: TARGET	18
4.4.3 Tipología de variables	18
4.4.4 Particularidades y primera exploración	19
5. Capítulo 2: Análisis exploratorio de los datos (EDA)	19
5.1 - Distribución del target: el problema del desbalanceo	19
5.2 - Análisis de valores nulos	21
5.3 - Análisis estadístico descriptivo	22
5.4 - Gestión de variables de vivienda: multicolinealidad	23
5.5 - Corrección de anomalías	24
5.6 - Correlaciones entre variables	24
6. Capítulo 3: Preprocesamiento y Feature Engineering	27

6.1 - Tratamiento de valores nulos (MNAR)	27
6.2 - Codificación de variables (Encoding)	28
6.3 - Ingeniería de características financieras	28
6.3.1 - Ratios de Capacidad de Pago	28
6.3.2 - Variables de Estabilidad y Perfil Demográfico	29
6.3.3 - Estrés de Liquidez (Goods Price Diff)	29
6.3.4 - Consenso de Fuentes Externas	30
6.3.5 - Variable adicional	30
6.4 - División del dataset: prevención del Data Leakage	30
6.5 - Imputación y escalado (post-split)	31
6.6 - Selección de variables	31
6.7 - Balanceo de clases: SMOTE vs Ponderación	33
7. Capítulo 4: Entrenamiento de evaluación	33
7.1 - Métricas de evaluación	34
7.2 - Random Forest (con SMOTE)	35
7.3 - LightGBM (con SMOTE)	37
7.4 - LightGBM con Ponderación Nativa (Sin SMOTE)	38
7.5 - SVM - LinearSVC	39
7.6 - Red Neuronal MLP	39
8. Capítulo 5: Elección del modelo	40
8.1 - Tabla comparativa del benchmark	41
8.2 - Análisis del umbral de decisión	42
8.3 - Justificación del modelo ganador	44
9. Capítulo 6: Explicabilidad del modelo (XAI con SHAP)	46
9.1 - Por qué la explicabilidad es obligatoria en banca	46
9.2 - Análisis global: variables más influyentes	46
9.3 - Análisis individual: un caso real	48
10. Capítulo 7: Exportación del modelo	50
11. Capítulo 8: Despliegue en Hugging Face	51
12. Conclusiones y líneas futuras de trabajo	52
13. Bibliografía	53

1. Resumen

Este trabajo desarrolla un sistema capaz de predecir si un cliente de un banco va a devolver su préstamo o no usando técnicas de Machine Learning. Para todo esto se ha usado el dataset público de “Home Credit Default Risk”, compuesto por más de 307.000 solicitudes de préstamo reales. Mediante técnicas de Machine Learning, se ha ido construyendo un pipeline completo que incluye análisis exploratorio de datos, limpieza, ingeniería de características financieras y el entrenamiento de 5 modelos de clasificación distintos. El modelo ganador ha sido LightGBM con ponderación interna de clases, este alcanza un área bajo la curva ROC (AUC) de 0,756 y detecta unos 7 de cada 10 casos de impago. Adicionalmente, se aplican técnicas de IA Explicable (XAI) mediante SHAP para garantizar la transparencia del modelo, un requisito fundamental en el sector bancario europeo. El modelo final ha sido publicado en Hugging Face para facilitar su reutilización.

2. Introducción

2.1- Motivación

Problema económico: Cada año los bancos pierden millones por impagos de préstamos, por ejemplo el “Banco Central Europeo” reporta que la tasa de préstamos morosos en la UE rondó el 1,5–2% en los últimos años, lo que en valor absoluto representa cientos de millones de euros. Todo esto justifica que automatizar la detección sea algo crítico (Banco Central Europeo, 2023).

La brecha de los sistemas tradicionales: Los métodos tradicionales de scoring crediticio (como el score FICO o los modelos lógicos simples) (Anderson, 2007) llevan décadas en uso pero tienen limitaciones: no capturan relaciones no lineales entre variables, no escalan bien a grandes volúmenes de datos y a menudo excluyen a personas sin historial bancario formal (como los clientes del dataset, que son precisamente el caso de uso de este TFM).

2.2 - Objetivos

Objetivo general:

Desarrollar un modelo de clasificación binaria supervisada que estime la probabilidad de impago de un cliente financiero, aplicando un enfoque orientado a la viabilidad profesional y al cumplimiento normativo bancario en Europa.

Objetivos específicos:

1. Realizar un análisis exploratorio completo del dataset para comprender la naturaleza y distribución de los datos
2. Aplicar un pipeline de preprocesamiento riguroso que evite el Data Leakage y preserve la integridad estadística del modelo.
3. Crear variables financieras derivadas (Feature Engineering) basadas en la lógica de negocio bancario
4. Entrenar y comparar cinco modelos de clasificación binaria mediante un benchmark sistemático
5. Seleccionar el modelo con el mejor equilibrio entre capacidad predictiva (AUC) y detección de impagos (Recall).
6. Aplicar técnicas de Inteligencia Artificial Explicable (XAI) con SHAP para interpretar los resultados y las decisiones de los modelos.
7. Publicar el modelo en Hugging Face para garantizar el acceso abierto.

2.3 - Tecnologías y herramientas utilizadas

Python



Lenguaje de programación de alto nivel, estándar en ciencia de datos y aprendizaje automático. Es el lenguaje principal en el que he desarrollado todo el código del proyecto, desde la lectura del dataset hasta el despliegue final.

Jupyter

Notebook

Entorno interactivo basado en celdas que permite combinar código, visualizaciones y explicaciones en un único documento. Se ha utilizado como entorno de desarrollo principal del TFM, facilitando el análisis y la documentación paso a paso del pipeline.



Matplotlib



Librería base de visualización en Python. Se ha utilizado para generar gráficos esenciales del proyecto como la curva ROC, las matrices de confusión y los gráficos de dispersión empleados durante el análisis.

Pandas

Librería de manipulación y análisis de datos tabulares. En este proyecto se ha empleado para la lectura del dataset (307.511 registros) la limpieza de datos, el tratamiento de nulos y la creación de las nuevas variables financieras (Feature Engineering)



Scikit-learn



Librería de ML de referencia en Python. Se ha utilizado de forma transversal en todo el pipeline: preprocesamiento (*SimpleImputer*, *StandardScaler*, *LabelEncoder*), partición de datos selección de variables (*SelectFromModel*), entrenamiento de modelos (*Random Forest*, *SVM*, *MLP*) y cálculo de métricas (*Roc_AUC*, *F1...*)

Numpy

Librería fundamental para el cálculo numérico en Python. En este proyecto se utilizó principalmente para gestionar los valores infinitos (*np.inf*) y nulos (*np.nan*) que surgían al crear ratios financieros, mediante la función *np.where* que evita divisiones por cero.



Seaborn



Librería de visualización construida sobre Matplotlib, especializada en gráficos estadísticos atractivos. En este TFM se ha empleado para generar el heatmap de correlaciones, los barplots de distribución de variable objetivo y otros gráficos de diagnóstico del EDA

LightGBM

Librería de Gradient Boosting desarrollada por Microsoft. En este proyecto se empleó como modelo ganador del benchmark aprovechando su parámetro nativo de ponderación de clases (*is_unbalance=True*) para gestionar el desbalanceo sin necesidad de datos sintéticos.



Imbalanced-learn (imblearn)



Librería complementaria de **Scikit-learn** especializada en datasets desbalanceados. Se ha empleado para aplicar la técnica SMOTE (Synthetic Minority Over-sampling

Technique), generando ejemplos sintéticos de la clase minoritaria (impagos) durante la fase experimental.

Hugging Face

Plataforma colaborativa de referencia en el ecosistema de IA abierta, considerada el “GitHub de los modelos de Machine Learning”. Se ha utilizado para publicar el modelo final del TFM en el repositorio público *IzanMoya/Credit-Scoring-Risk-Model-TFM* garantizando su reproducibilidad y trazabilidad



SHAP (SHapley Additive exPlanations)

Librería de Inteligencia Artificial Explicable basada en la teoría de juegos cooperativos. Se ha utilizado para interpretar el modeloganador (LightGBM), tanto a nivel global (qué variables son más **influyentes en el conjunto** del modelo) como a nivel individual (por qué se aprueba o rechaza un cliente concreto)



3. Marco Teórico

3.1 - El riesgo crediticio en la banca moderna

El riesgo crediticio es la probabilidad de que un prestatario no devuelva el capital que una entidad bancaria le ha concedido. Este fenómeno existe desde los orígenes de la banca, pero el desarrollo tecnológico y los nuevos modelos analíticos han incrementado considerablemente la capacidad para prevenirlo y gestionarlo. Desde los primeros sistemas bancarios desarrollados en COBOL en los años sesenta, hasta la consolidación de las técnicas de Machine Learning en las últimas décadas, la precisión en la predicción del riesgo ha mejorado de forma muy significativa.

El Banco Central Europeo publica trimestralmente el ratio NPL (*Non-Performing Loans*, o préstamos fallidos). En la zona euro, este indicador ronda actualmente el 1,5–2 % del total de préstamos, aunque en términos absolutos representa decenas de miles de millones de euros. A modo de referencia, tras la crisis

financiera de 2008, los bancos europeos llegaron a registrar ratios NPL superiores al 8 %, situando al sistema financiero al borde del colapso (Banco Central Europeo, 2023).

A lo largo de la historia, las entidades bancarias han utilizado modelos de scoring crediticio. Entre los más extendidos se encuentran el score FICO en Estados Unidos y los modelos basados en regresión logística en Europa (Anderson, 2007). Estos enfoques han demostrado su utilidad, pero presentan limitaciones estructurales relevantes (Thomas, 2009):

- Solo capturan relaciones lineales entre variables.
- Penalizan a quienes carecen de historial bancario formal, fenómeno conocido como *credit invisible*.
- No escalan eficientemente ante millones de variables y registros

Este panorama cambia con la incorporación del Big Data, el Machine Learning y la disponibilidad de capacidades de cómputo accesibles para gran parte del mercado. Las entidades financieras han comenzado a adoptar modelos de aprendizaje automático capaces de capturar patrones complejos y no lineales, mejorando significativamente la precisión predictiva (Thomas, 2009).

Un ejemplo representativo de este nuevo paradigma es la competición pública Home Credit Default Risk, que constituye el caso de uso de este TFM y se describe en detalle en el Capítulo 1.

3.2 - Análisis exploratorio de datos (EDA)

El Análisis Exploratorio de Datos (EDA, por sus siglas en inglés *Exploratory Data Analysis*) es la fase del proyecto en la que se descubre la naturaleza de los datos con los que se va a trabajar. Antes de procesarlos, resulta imprescindible comprenderlos, es como cuando se hacen una serie de pruebas médicas antes de una intervención quirúrgica. El propósito último es garantizar el uso adecuado de la información disponible.

El término EDA fue acuñado por John Tukey en 1977 en su obra *Exploratory Data Analysis*. Tukey defendía que, antes de aplicar técnicas estadísticas formales, era necesario explorar visualmente los datos y dejar que estos "hablen". De esta manera, se obtiene un mejor contexto del problema a resolver y se puede proceder de forma más fundamentada (Tukey, 1977).

Dentro de un EDA se aplican habitualmente las siguientes fases:

- Examinar la estructura del dataset (filas, columnas, tipos de variables)
- Detectar valores nulos o anómalos
- Calcular estadísticas descriptivas (media, mediana, desviación)
- Visualizar distribuciones mediante histogramas, boxplots u otros gráficos.
- Estudiar correlaciones entre variables

En un dataset financiero como el de Home Credit, el EDA permite descubrir desde el principio que las clases están desbalanceadas (con apenas un 8 % de impagos), que existen variables redundantes (como las múltiples métricas de vivienda) o que determinados valores son anómalos (por ejemplo, registros que indican un cliente empleado durante más de 1.000 años, como se verá en el Capítulo 2).

3.3 - Desequilibrio de clases y técnicas de tratamiento

En muchos problemas reales de clasificación, las dos clases no están equilibradas. En este caso, únicamente el 8 % de los clientes son impagadores, frente al 92 % de buenos pagadores. Esta misma asimetría aparece en problemas como la detección de fraude (donde la mayoría de las transacciones son legítimas) o el diagnóstico médico (donde la mayoría de los pacientes están sanos) (He & Garcia, 2009).

Existen tres grandes familias de técnicas para abordar el desbalanceo:

1. **Sobremuestreo (*Oversampling*)**: consiste en aumentar artificialmente la clase minoritaria.
 - a. *Sobremuestreo aleatorio*: duplica registros de impago, con el consiguiente riesgo de sobreajuste (*overfitting*).
 - b. *SMOTE (Synthetic Minority Over-sampling Technique)*: introducido por Chawla et al. (2002). En lugar de duplicar registros, genera nuevos ejemplos sintéticos interpolando entre vecinos cercanos de la clase minoritaria. Es la técnica más extendida a nivel mundial para tratar el desbalanceo de clases.
2. **Submuestreo (*Undersampling*)**: consiste en eliminar ejemplos de la clase mayoritaria. Implica una pérdida de información valiosa, aunque puede resultar útil cuando se trabaja con millones de registros.

3. **Ponderación de clases (*Class Weights*):** en lugar de modificar los datos, se modifica el algoritmo. Se le indica que un error sobre un impago "duele" mucho más que un error sobre un buen pagador. El algoritmo LightGBM lo implementa nativamente mediante el parámetro **is_unbalance=True**. Su ventaja principal es que no introduce ruido sintético y mantiene la distribución real de los datos.

En este TFM se compararon empíricamente SMOTE y la ponderación nativa, observándose que esta última resulta claramente superior para los algoritmos basados en Boosting, como se demostrará en el Capítulo 4.

Otro concepto fundamental cuando se trabaja con datos reales es el de los datos faltantes. Existen tres mecanismos clásicos: MCAR (Missing Completely At Random), MAR (Missing At Random) y MNAR (Missing Not At Random). En este último, el más complejo, la ausencia del dato no es casual sino que depende del propio valor que no se observa, lo que convierte la propia ausencia en una variable potencialmente predictiva (Little & Rubin, 2019)

3.4 - Ingeniería de características (*Feature Engineering*)

La ingeniería de características es el proceso de transformar datos crudos en variables más útiles para el modelo. Su impacto suele ser superior al de cambiar el algoritmo — de ahí la conocida observación del académico Andrew Ng: "*Applied machine learning is basically feature engineering*" (Ng, 2014). Si a un analista bancario se le proporcionan los ingresos y la cuota de un cliente por separado, lo primero que calculará mentalmente es el porcentaje de ingresos destinado al pago. El *Feature Engineering* consiste en enseñar al modelo a realizar esos cálculos de forma automática (Kuhn & Johnson, 2019).

En el sector bancario son especialmente relevantes los ratios financieros (deuda/ingreso, crédito/garantía), las variables agregadas (medias o mínimos sobre grupos de fuentes externas), las transformaciones temporales (días a años, ratios de antigüedad laboral) y los indicadores binarios que señalan la presencia o ausencia de una característica. Estos cuatro tipos se aplican en el Capítulo 3,

donde se desarrollan los bloques de Capacidad de Pago, Estabilidad Demográfica, Estrés de Liquidez y Consenso de Fuentes Externas.

Destaca que las soluciones ganadoras de la competición Kaggle *Home Credit Default Risk* no se diferenciaron por usar algoritmos exóticos, sino por una ingeniería de variables extremadamente sofisticada sobre las siete tablas del dataset. Este TFM adopta un enfoque diferente: extraer el máximo poder predictivo de una sola tabla mediante variables financieras basadas en lógica de negocio bancario real.

3.5 - Modelos de clasificación supervisada

Existen numerosas familias de algoritmos de clasificación, cada una con un enfoque matemático diferente. En este TFM se han evaluado cinco modelos, representativos de las grandes corrientes del Machine Learning aplicadas a datos tabulares.

3.5.1 Random Forest(Bosques Aleatorios) - Familia: Bagging

Propuesto por Breiman (2001), construye cientos de árboles de decisión sobre muestras aleatorias y promedia su voto — análogo a una asamblea donde la decisión conjunta es más fiable que la de un individuo aislado. Es robusto y capaz de gestionar variables mixtas, aunque en datos tabulares complejos suele quedar por debajo de los algoritmos de Gradient Boosting en rendimiento.

3.5.2 LightGBM(Light Gradient Boosting Machine) - Familia: Gradient Boosting

Desarrollado por Microsoft (Ke et al., 2017), este modelo construye los árboles de forma secuencial: cada nuevo árbol corrige los errores del anterior, de forma análoga a un alumno que aprende de sus equivocaciones. Es el estado del arte en datos tabulares, con alta velocidad de entrenamiento y gestión nativa del desbalanceo mediante el parámetro **is_unbalance**; como contrapartida, es más sensible al sobreajuste que Random Forest si no se regulariza correctamente.

3.5.3 SVM(Support Vector Machines) - Familia: Modelos geométricos

Desarrollado por Cortes y Vapnik (1995), SVM busca trazar la frontera que separa los clientes "buenos" de los "malos" con el mayor margen geométrico

posible. En este TFM se ha utilizado la variante *LinearSVC*, ya que con más de 300.000 registros el uso de un *kernel* era inviable computacionalmente. Su principal limitación en este contexto es que no devuelve probabilidades

calibradas de forma directa, lo que dificulta su integración en un motor de decisión bancario real.

3.5.4 Multilayer Perceptron(MLP) - Red Neuronal Artificial - Familia: *Deep Learning*

El Perceptrón Multicapa, inspirado en el funcionamiento de las neuronas biológicas, aprende representaciones complejas encadenando capas de neuronas matemáticas. Aunque destaca en problemas no estructurados (imagen, texto, audio), en datos tabulares no suele superar al *Gradient Boosting* (Shwartz-Ziv & Armon, 2022), y añade un coste computacional y una opacidad que lo hacen poco viable en producción bancaria.

La elección final del modelo no se basa en intuiciones, sino en un *benchmark* sistemático que se detalla en el Capítulo 4.

3.6 - Explicabilidad del modelo: XAI y SHAP

Los modelos modernos de Machine Learning pueden ser muy precisos, pero también opacos. Si LightGBM rechaza un préstamo, no es trivial saber por qué. En muchos sectores este nivel de opacidad sería tolerable, pero en banca resulta inaceptable.

La XAI (*eXplainable Artificial Intelligence*) es el conjunto de técnicas que buscan hacer interpretables las decisiones de los modelos de IA. Surge como respuesta a la creciente complejidad de los algoritmos y a las exigencias regulatorias actuales (Molnar, 2022).

La explicabilidad se enmarca en un contexto normativo cada vez más exigente:

- **GDPR (Reglamento General de Protección de Datos UE, 2016):** en su artículo 22, otorga a los ciudadanos el "derecho a una explicación" sobre las decisiones automatizadas que les afecten significativamente.
- **Basilea III/IV (Comité de Supervisión Bancaria de Basilea, 2017):** obliga a las entidades financieras a justificar sus modelos de riesgo ante los reguladores.

- **EU AI Act (Reglamento UE 2024/1689)**: clasifica los sistemas de scoring crediticio como aplicaciones de "alto riesgo", exigiendo trazabilidad y explicabilidad obligatorias.

Dentro de las técnicas de XAI destaca SHAP (*SHapley Additive exPlanations*). Propuesto por Lundberg y Lee (2017), se basa en los **valores de Shapley**, un concepto procedente de la teoría de juegos cooperativos formulado originalmente por Lloyd Shapley (Premio Nobel de Economía en 2012). La pregunta original es: si varios jugadores cooperan, ¿cómo se reparte de forma justa la recompensa según la contribución de cada uno? SHAP traslada esta pregunta al Machine Learning: ¿cómo se reparte de forma justa la "responsabilidad" de una predicción entre las distintas variables del modelo?

La respuesta se traduce en un valor SHAP para cada variable de cada predicción, indicando cuánto y en qué dirección empuja dicha variable la decisión final del modelo.

Los principales tipos de gráficos SHAP utilizados en este trabajo son:

- **Beeswarm Plot**: visión global del impacto y la dirección de cada variable.
- **Bar Plot**: importancia global agregada de las variables.
- **Waterfall Plot**: explicación individual de un cliente concreto.

En definitiva, la explicabilidad es lo que permite que un modelo de Machine Learning pueda usarse de forma real en el sector bancario, y no solo como ejercicio académico. Por este motivo, el modelo final del TFM se acompaña de un análisis SHAP completo, que se desarrollará en el Capítulo 6.

3.7 - Despliegue con Hugging Face

Hugging Face es la plataforma colaborativa de referencia en el ecosistema de IA abierta, considerada el "GitHub del Machine Learning". Permite alojar modelos con versionado completo, acompañados de una Model Card — ficha estandarizada que documenta métricas, datos de entrenamiento, limitaciones éticas y licencia. Esta transparencia la convierte en la opción natural para publicar el modelo de este TFM cumpliendo los requisitos de trazabilidad de Basilea y el EU AI Act, tal como se desarrolla en el Capítulo 8.

4. Capítulo 1: Contexto y descripción del dataset

4.1 - Contextualización del problema

Tal como se ha presentado en el Marco Teórico, el riesgo crediticio constituye uno de los principales retos de la banca moderna. Este TFM aborda dicho problema desde un caso real: el de la entidad financiera **Home Credit**.



Home Credit es una empresa internacional de origen neerlandés fundada en 1997. Se especializa en conceder préstamos a clientes sin historial bancario tradicional, lo que le permite acceder a un segmento de mercado al que las entidades convencionales no suelen llegar. Opera principalmente en mercados emergentes como Rusia, China, India, Vietnam o Filipinas. Su modelo de negocio depende íntegramente de la calidad de su sistema de scoring para clasificar a los solicitantes: si acierta, obtiene beneficios; si falla, asume pérdidas directas (Home Credit Group, 2018).

En 2018, la entidad decidió hacer públicos sus datos a través de la plataforma Kaggle con un doble objetivo: mejorar sus propios modelos internos de scoring y aprovechar el conocimiento colectivo de la comunidad de ciencia de datos. La competición ofreció un premio total de 70.000\$ al mejor modelo y reunió a más de 7.000 equipos de todo el mundo, convirtiéndose en una de las competiciones más relevantes de la plataforma en el ámbito financiero.

El objetivo de este TFM consiste en predecir, dado un conjunto de variables socioeconómicas, demográficas y financieras de un solicitante de préstamo, la probabilidad de que dicho solicitante incurra en impago (*default*). Formalmente, se trata de un problema de **clasificación binaria supervisada** en el que la variable objetivo (**TARGET**) toma dos valores: 1 (impago) o 0 (pago).

Las soluciones de Kaggle se basaron mayoritariamente en ensamblajes masivos sobre las siete tablas satélite del dataset, alcanzando valores de AUC cercanos a 0,80. Este TFM, en cambio, adopta un **enfoque Lean**: trabajar únicamente con la tabla principal (**application_train.csv**) y construir un modelo competitivo (AUC > 0,75) pero **100 % interpretable**, priorizando la viabilidad profesional y el

cumplimiento normativo bancario europeo. Esta es la principal diferencia respecto a las típicas soluciones "caja negra" presentadas en la competición.

4.2 - Marco normativo bancario

El sector bancario es probablemente el más regulado del mundo. Cualquier modelo predictivo que tome decisiones sobre clientes debe cumplir con un conjunto de normativas internacionales y europeas. En este apartado se presentan las tres más relevantes para este TFM.

4.2.1 Acuerdos de Basilea (III y IV)

Los **Acuerdos de Basilea** son un conjunto de recomendaciones internacionales sobre regulación bancaria emitidas por el **Comité de Supervisión Bancaria de Basilea (BCBS)**, ubicado en el Banco de Pagos Internacionales(BIS). Su objetivo es garantizar la estabilidad del sistema financiero mundial.

- **Basilea III** (publicado en 2010 tras la crisis financiera de 2008): exige a los bancos calcular su capital regulatorio en función del riesgo de sus activos. Para ello, las entidades deben disponer de modelos internos de scoring crediticio que sean **transparentes, auditables y reproducibles** (Comité de Supervisión Bancaria de Basilea, 2017).
- **Basilea IV** (en proceso de implementación con horizonte 2025-2028): refuerza estas exigencias, limita el uso de modelos puramente internos y obliga a una **mayor estandarización y trazabilidad** de los modelos empleados.

Para este TFM, Basilea implica que cualquier modelo desarrollado debe poder ser explicado y justificado ante un regulador. Por este motivo, los modelos de "caja negra" sin interpretabilidad (como las redes neuronales profundas sin análisis de explicabilidad asociado) resultan inviables en producción bancaria.

4.2.2 GDPR (Reglamento General de Protección de Datos, UE 2016/679)

El **GDPR** entró en vigor en mayo de 2018 y regula el tratamiento de datos personales en la Unión Europea. Es directamente aplicable a este TFM por dos motivos:

- **Artículo 22:** otorga al ciudadano el derecho a no ser sometido a decisiones basadas únicamente en tratamiento automatizado que le afecten significativamente. En el contexto bancario, esto incluye la denegación automática de un préstamo.

- **Derecho a la explicación:** el ciudadano tiene derecho a recibir información significativa sobre la lógica empleada en la decisión automatizada que le afecta (Reglamento UE 2016/679).

En la práctica, esto convierte la explicabilidad (XAI) en una **obligación legal**, no en una mera opción técnica. Es precisamente este punto el que motiva el Capítulo 6 del TFM, dedicado al análisis SHAP.

4.2.3 EU AI Act (Reglamento UE 2024/1689)

El EU AI Act, aprobado en 2024, es el primer marco normativo integral del mundo sobre inteligencia artificial. Clasifica los sistemas de IA en cuatro niveles de riesgo: mínimo, limitado, alto e inaceptable (Reglamento UE 2024/1689). Los sistemas de *scoring* crediticio se clasifican explícitamente como "alto riesgo" (Anexo III del Reglamento), lo que impone al desarrollador obligaciones de documentación técnica detallada, trazabilidad de las decisiones y supervisión humana de los procesos.

Este marco normativo justifica las decisiones técnicas tomadas en este TFM: la priorización de modelos interpretables (LightGBM frente a redes neuronales profundas), el uso de SHAP para garantizar la explicabilidad y la publicación del modelo acompañado de una *Model Card* transparente en Hugging Face.

4.3 - Fuentes de datos

4.3.1 Origen del dataset

El conjunto de datos utilizado en este TFM procede de la competición pública "**Home Credit Default Risk**", publicada por Home Credit Group en Kaggle en 2018. Los datos están anonimizados y representan un histórico real de solicitudes de préstamo recibidas por la entidad en los distintos países donde opera.

El dataset completo está compuesto por **siete tablas relacionadas** mediante claves primarias:

Tabla	Contenido	Volumen aproximado
application_train.csv	Datos del solicitante en el momento de la solicitud actual	307.511 filas

application_test.csv	Mismas variables, sin etiqueta	48.744 filas
bureau.csv	Histórico de créditos del cliente en otras entidades	1,7 millones
bureau_balance.csv	Detalle mensual de los créditos anteriores	27 millones
previous_application.csv	Solicitudes anteriores del cliente en Home Credit	1,6 millones
POS_CASH_balance.csv	Histórico mensual de créditos en tienda y en efectivo	10 millones
installments_payments.csv	Histórico de pagos realizados	13 millones
credit_card_balance.csv	Histórico mensual de tarjetas de crédito anteriores	3,8 millones

4.3.2 Decisión metodológica: enfoque Lean sobre una sola tabla

Este TFM trabaja exclusivamente con **application_train.csv**. La decisión se justifica por viabilidad profesional (una entidad financiera real partiría también de una tabla maestra antes de incorporar fuentes adicionales), interpretabilidad (una sola tabla mantiene la trazabilidad directa de cada variable, eficiencia computacional (307.000 registros y 122 variables son suficientes para modelos robustos sin infraestructura distribuida) y diferenciación metodológica frente a las soluciones de Kaggle, que se basaron en *feature engineering* masivo sobre las siete tablas satélite. Este TFM extrae el máximo poder predictivo de la tabla principal mediante Feature Engineering basado en la lógica de negocio.

4.3.3 Fichero complementario

Junto al dataset principal se ha utilizado el fichero

HomeCredit_columns_descriptions.csv, que contiene la descripción semántica de cada variable del dataset (significado, unidades, valores posibles). Este fichero ha sido esencial para interpretar correctamente cada columna en el contexto del negocio bancario, especialmente durante las fases de análisis exploratorio e ingeniería de características.

4.4 -Estructura y lectura del dataset

4.4.1 Dimensiones del dataset

El fichero **application_train.csv** se carga en memoria utilizando la librería Pandas mediante la función *pd.read_csv()*. Una vez cargado, presenta las siguientes dimensiones iniciales:

- **307.511 registros** (filas) → donde cada uno representa una solicitud de préstamo única.
- **122 variables** (columnas) → incluyendo la variable objetivo **TARGET** y el id único **SK_ID_CURR**

4.4.2 La variable objetivo: TARGET

La variable a predecir es **TARGET**, una variable binaria que toma dos valores:

- **0**: el cliente devolvió el préstamo correctamente (cliente bueno).
- **1**: el cliente incurrió en impago (cliente moroso).

Esta variable presenta un fuerte desbalanceo (aproximadamente un 92 % de ceros frente a un 8 % de unos), lo que condicionará las decisiones técnicas posteriores, tal como se ha explicado en el apartado 3.3.

4.4.3 Tipología de variables

Las 122 variables del dataset se pueden agrupar en siete grandes categorías según el contenido que recogen:

Categoría	Ejemplos	Tipo
Identificación	SK_ID_CURR	Numérica entera
Datos demográficos	CODE_GENDER, DAYS_BIRTH, CNT_CHILDREN, NAME_FAMILY_STATUS	Mixto
Datos financieros	AMT_INCOME_TOTAL, AMT_CREDIT, AMT_ANNUITY, AMT_GOODS_PRICE	Numéricas
Datos laborales	DAYS_EMPLOYED, OCCUPATION_TYPE, NAME_INCOME_TYPE	Mixto
Datos de vivienda	Variables terminadas en _AVG, _MODE, _MEDI	Numéricas
Fuentes externas	EXT_SOURCE_1, EXT_SOURCE_2, EXT_SOURCE_3	Numéricas

Indicadores binarios	FLAG_OWN_CAR, FLAG_OWN_REALTY, FLAG_DOCUMENT_*	Binarias
----------------------	---	----------

4.4.4 Particularidades y primera exploración

Antes de cualquier análisis, se identifican dos características del dataset que condicionan decisiones posteriores: las variables temporales (**DAYS_BIRTH**, **DAYS_EMPLOYED**) están expresadas en días negativos desde la solicitud, y las variables **EXT_SOURCE_1/2/3** representan *scorings* de burós externos que, según la literatura, son los predictores univariantes más potentes del dataset.

La exploración inicial se realiza con las funciones estándar de Pandas: **df_train.head()**, **df_train.shape**, **df_train.info()** y **df_train.describe()**. Estos pasos constituyen el punto de partida del EDA desarrollado en el Capítulo 2.

5. Capítulo 2: Análisis exploratorio de los datos (EDA)

Una vez presentado el contexto del problema y la estructura general del dataset, el presente capítulo aborda el Análisis Exploratorio de Datos (EDA), siguiendo la metodología descrita en el apartado 3.2 del Marco Teórico. El objetivo es comprender en profundidad la naturaleza, calidad y distribución de los datos antes de aplicar cualquier transformación o algoritmo. Este análisis previo es el que permite tomar decisiones fundamentadas en las fases posteriores de preprocesamiento y modelado.

5.1 - Distribución del target: el problema del desbalanceo

El primer análisis de cualquier proyecto de clasificación supervisada debe centrarse en la variable que se quiere predecir. La distribución del *target* determina muchas decisiones técnicas posteriores: la elección de las métricas, las técnicas de balanceo y, en ocasiones, incluso la familia de modelos a utilizar.

El recuento exacto de registros del dataset revela las siguientes cifras:

- **Total de registros:** 307.511
- **Clase 0 (buenos pagadores):** 282.686 registros ($\approx 92\%$)
- **Clase 1 (impagadores):** 24.825 registros ($\approx 8\%$)
- **Ratio de desbalanceo aproximado:** 11 a 1




Figura 5.1. *Distribución de la variable objetivo TARGET en el dataset*

La Figura 5.1 muestra de forma clara el fuerte desbalanceo entre ambas clases. La gran diferencia visual entre las dos barras anticipa que, sin tratamiento específico, el modelo tendrá una tendencia natural a aprender mejor los patrones de la clase mayoritaria (clientes que pagan), por lo que será imprescindible aplicar técnicas específicas para el tratamiento del desbalanceo, tal como se justificó en el apartado 3.3.

Todo esto tiene 3 consecuencias directas:

- **No usar *accuracy* como métrica principal**, ya que sería engañosa en un contexto tan desbalanceado. En el apartado 7.1 se justifica el uso de AUC y Recall como métricas de referencia.
- **Aplicar técnicas de balanceo de clases**: tanto el sobremuestreo sintético con SMOTE como la ponderación de clases, comparadas empíricamente en el apartado 6.7
- **Estratificar la partición train/validation/test**, para mantener la proporción de clases en los tres subconjuntos y evitar sesgos por reparto desigual. Esto se detalla en el apartado 6.4.

5.2 - Análisis de valores nulos

En la mayoría de proyectos de ciencia de datos, los valores nulos se imputan de forma genérica, sin un análisis previo del motivo de su ausencia. En riesgo crediticio, sin embargo, el hecho de que falte un dato es a menudo **una señal de comportamiento en sí mismo**. Este fenómeno se conoce en estadística como **MNAR** (*Missing Not At Random*), un mecanismo de pérdida de datos en el que la probabilidad de que un valor falte depende directamente del propio valor no observado. Es decir, existe una razón sistemática y oculta por la que el dato no está presente (Little & Rubin, 2019).

Al aplicar la función **missing_data()** definida sobre el dataset, se obtienen los siguientes hallazgos cuantitativos:

- De las 122 columnas iniciales, **más de la mitad presentan al menos un valor nulo**.
- Las columnas con mayor proporción de nulos son las **variables de vivienda** (**COMMONAREA_AVG**, **NONLIVINGAPARTMENTS_AVG**, entre otras), llegando a superar el **69 % de valores faltantes**.
- Otras variables relevantes con un porcentaje elevado de nulos son: **OWN_CAR_AGE** ($\approx 66\%$), **EXT_SOURCE_1** ($\approx 56\%$) y **OCCUPATION_TYPE** ($\approx 31\%$).

Tabla 5.1. Top 10 de columnas con mayor porcentaje de valores nulos

	Total	Porcentaje
COMMONAREA_AVG	214865	69.87229
COMMONAREA_MEDI	214865	69.87229
COMMONAREA_MODE	214865	69.87229
NONLIVINGAPARTMENTS_AVG	213514	69.43296
NONLIVINGAPARTMENTS_MEDI	213514	69.43296
NONLIVINGAPARTMENTS_MODE	213514	69.43296
FONDKAPREMONT_MODE	210295	68.38617
LIVINGAPARTMENTS_MEDI	210199	68.35495
LIVINGAPARTMENTS_AVG	210199	68.35495
LIVINGAPARTMENTS_MODE	210199	68.35495

El análisis cualitativo revela que cada nulo obedece a una causa distinta: en **OWN_CAR_AGE** el nulo indica ausencia del activo (informativo); en **OCCUPATION_TYPE**, que el cliente no declaró su ocupación (potencialmente predictivo, ya que los clientes que omiten información tienden a presentar mayor riesgo); en las variables de vivienda **_AVG**, que Home Credit no pudo obtener

datos relevantes en ciertos mercados (no informativo); y en EXT_SOURCE_1, que no existe scoring externo para ese cliente (altamente informativo). Esta heterogeneidad impide aplicar una estrategia genérica de imputación, como se desarrolla en el apartado 6.1.

5.3 - Análisis estadístico descriptivo

Para el análisis descriptivo completo del dataset se ha empleado la función **describe()** de la librería **Pandas**, que devuelve los estadísticos básicos (**count**, **mean**, **std**, **min**, percentiles 25 %, 50 %, 75 % y **max**) para todas las variables numéricas.

Dentro de esta descripción general, se destacan cuatro variables financieras y demográficas clave por su importancia en la lógica de negocio :

Tabla 5.2. Estadísticos descriptivos de las variables financieras y demográficas principales

Variable	Significado	Media	Mediana	Mín	Máx
AMT_INCOME_TOTAL	Ingresos anuales del cliente	168.798	147.150	25.650	117 mill
AMT_CREDIT	Importe del préstamo solicitado	599.026	513.531	45.000	4 mill
AMT_ANNUITY	Cuota anual del préstamo	27.108	24.903	1.615	258.000
DAYS_BIRTH	Edad en días (negativos)	-16.037	-15.750	-25.229	-7.489

Las tres variables financieras principales muestran una asimetría positiva característica: la media de **AMT_INCOME_TOTAL** (168.798) supera en un 15% a la mediana (147.150), y en **AMT_CREDIT** la diferencia es de casi 85.000 unidades, ambas señales de la presencia de *outliers* en los valores altos. La cuota anual media (**AMT_ANNUITY** $\approx$ 27.108) representa aproximadamente el 16% de los ingresos del cliente tipo, ratio que anticipa la variable **PAYMENT_RATE** creada en el *Feature Engineering* del Capítulo 3.

La edad (**DAYS_BIRTH**), expresada en días negativos, equivale a una media de 44 años (rango 21–69). Esta variable será transformada a años en el Capítulo 3

para facilitar la interpretabilidad del modelo (**AGE_YEARS**). Adicionalmente, el análisis detecta dos anomalías que se abordan en el apartado 5.5: **DAYS_EMPLOYED** presenta un valor máximo de 365.243 días (≈ 1.000 años) y **CODE_GENDER** contiene 4 registros con valor XNA.

Este análisis estadístico permite identificar tanto la naturaleza general de las variables (rangos, escalas, distribuciones) como anomalías puntuales que requieren tratamiento específico antes de modelar.

5.4 - Gestión de variables de vivienda: multicolinealidad

Durante la inspección del dataset se detectan grupos de variables que se repiten con tres sufijos: **_AVG**, **_MODE** y **_MEDI** (por ejemplo, **APARTMENTS_AVG**, **APARTMENTS_MODE**, **APARTMENTS_MEDI**). Cada terna representa la misma medición sobre la vivienda del cliente expresada como media, moda y mediana, generando multicolinealidad: situación en la que dos o más variables predictoras están altamente correlacionadas y aportan información redundante, lo que incrementa la dimensionalidad y el riesgo de *overfitting*.

La correlación de Pearson entre los estadísticos de cada terna supera en todos los casos el umbral de 0,9 a partir del cual se considera redundancia práctica (Tabla 5.3).

Tabla 5.3. Correlaciones de Pearson entre los estadísticos de las variables de vivienda (ejemplos representativos)

Pareja de variables	Correlación Pearson
APARTMENTS_AVG vs APARTMENTS_MODE	0,99
APARTMENTS_AVG vs APARTMENTS_MEDI	0,98
BASEMENTAREA_AVG vs BASEMENTAREA_MODE	0,98
LIVINGAREA_AVG vs LIVINGAREA_MEDI	0,99

Decisión adoptada: conservar las variables **_AVG** (media aritmética, el estadístico más representativo en variables continuas) y eliminar **_MODE** **_MEDI**. Resultado: 33 columnas eliminadas, pasando de 122 a 89 variables.

5.5 - Corrección de anomalías

El análisis estadístico previo reveló dos anomalías que deben corregirse antes del modelado.

La variable **DAYS_EMPLOYED** presenta un valor máximo de 365.243 días ($\approx$ 1.000 años), claramente erróneo. Este valor es un código interno de Home Credit que marca a clientes no empleados (desempleados, jubilados, estudiantes). Si se deja sin tratar, el modelo los interpretaría como "empleados durante milenios", distorsionando correlaciones y capacidad predictiva. **Solución:** sustituir 365.243 por **np.nan** para que reciba el tratamiento estándar de valores faltantes.

La variable **CODE_GENDER** contiene 4 registros con el valor residual **XNA** sobre un total de 307.511. Imputarles un género arbitrario introduciría sesgo en una variable demográfica sensible; al representar únicamente el 0,001 % del dataset, se opta por **eliminar esos 4 registros**, sin impacto estadístico apreciable.

En ambos casos se ha optado por **eliminar o anular** en lugar de imputar, porque imputar un género (asignando arbitrariamente **M** o **F**) introduciría un sesgo artificial sobre una variable demográfica sensible. Los 4 registros suponen apenas un **0,001 %** del dataset, por lo que su eliminación no afecta en absoluto a la representatividad estadística del conjunto.

El dataset resultante tras estas dos correcciones queda libre de las anomalías estructurales más evidentes y listo para las fases posteriores de tratamiento de nulos y *Feature Engineering*, que se abordan en el Capítulo 3.

5.6 - Correlaciones entre variables

Una vez completado el análisis univariante (variable a variable), el siguiente paso es estudiar las **relaciones bivariantes**: ¿qué variables se relacionan entre sí?, y sobre todo, ¿cuáles se relacionan más con la variable objetivo **TARGET**?

Para este análisis se ha empleado la **correlación de Pearson**, que mide la relación lineal entre dos variables numéricas. Toma valores entre -1 y $+1$: los valores próximos a $+1$ indican que, cuando una variable sube, la otra también lo hace; los valores cercanos a -1 indican la relación inversa; y los valores próximos a 0 indican ausencia de relación lineal.

Correlaciones con la variable objetivo

Las variables más correlacionadas con **TARGET** se presentan a continuación, separando las correlaciones negativas (variables protectoras: cuando aumentan, reducen el riesgo de impago) de las positivas (variables de riesgo: cuando aumentan, incrementan la probabilidad de impago):

Correlaciones negativas (variables protectoras):

- **EXT_SOURCE_3** = -0,18
- **EXT_SOURCE_2** = -0,16
- **EXT_SOURCE_1** = -0,15
- **DAYS_BIRTH** = -0,08 (al ser negativa: clientes más mayores, menos riesgo)

Correlaciones positivas (variables de riesgo):

- **DAYS_EMPLOYED** = 0,07
- **REGION_RATING_CLIENT** = 0,06
- **DAYS_LAST_PHONE_CHANGE** = 0,06




Figura 5.2. Top 15 de variables más correlacionadas con TARGET.

El hecho de que las tres variables **EXT_SOURCE** (scorings de burós externos) sean las más correlacionadas con el **TARGET** confirma una hipótesis

ampliamente aceptada en la industria: **la opinión consolidada de otros burós de crédito es el predictor individual más potente del riesgo de impago**. Esta evidencia respalda directamente la decisión, tomada en la fase de *feature engineering*, de generar variables agregadas sobre estas tres fuentes externas (media, mínimo, máximo y producto), que se desarrollará en el apartado 6.3.

Detección de correlaciones entre predictores

Más allá de la relación con el **TARGET**, el análisis revela también la existencia de **correlaciones elevadas entre algunas variables predictoras**. La más destacable es la que se observa entre **AMT_CREDIT** (importe del préstamo solicitado) y **AMT_GOODS_PRICE** (precio del bien financiado), con una correlación cercana a **0,99**.

Este hallazgo es lógico desde el punto de vista del negocio: el importe de un préstamo suele coincidir aproximadamente con el precio del bien que se desea financiar. Sin embargo, **la diferencia entre ambos no es trivial**: cuando un cliente solicita un préstamo significativamente mayor que el precio del bien, está pidiendo liquidez adicional para otros fines (gastos no declarados, refinanciación de otras deudas, etc.), lo que empíricamente se asocia con un **mayor riesgo de impago**.

Este insight anticipa la creación, en el apartado 6.3, de dos variables derivadas que capturan precisamente esta lógica:

- **CREDIT_GOODS_DIFF**: diferencia absoluta entre el préstamo solicitado y el precio del bien.
- **CREDIT_GOODS_RATIO**: ratio entre ambos.

Con el análisis exploratorio completado, se dispone ya de una comprensión sólida del dataset: sus dimensiones, su calidad, las distribuciones de sus variables, las anomalías presentes y las relaciones entre ellas. En el siguiente capítulo, toda esta información se utiliza como base para tomar **decisiones informadas** en el preprocesamiento de los datos y en la creación de nuevas variables derivadas mediante *Feature Engineering*.

6. Capítulo 3: Preprocesamiento y Feature Engineering

El análisis exploratorio realizado en el capítulo anterior ha permitido identificar la calidad, la estructura y las particularidades del dataset. Sin embargo, los datos en

su estado actual no pueden alimentar directamente un modelo de Machine Learning: presentan valores nulos, variables categóricas en formato texto, anomalías corregidas que han generado nuevos nulos y, sobre todo, falta de variables derivadas que capturen la lógica de negocio. Este capítulo aborda la fase de preprocesamiento e ingeniería de características, en la que los datos se transforman en un conjunto numérico, limpio, escalado y enriquecido, listo para el entrenamiento de los modelos del Capítulo 4.

6.1 - Tratamiento de valores nulos (MNAR)

El análisis exploratorio reveló que los nulos del dataset no son aleatorios, sino que responden a mecanismos MNAR: su ausencia es en sí misma una señal potencialmente predictiva (Little & Rubin, 2019). Por ello la imputación se aborda caso por caso con tres estrategias diferenciadas:

- **Estrategia 1 — OWN_CAR_AGE:** imputación con 0. Si el cliente no tiene coche, no existe antigüedad del activo; el nulo equivale a ausencia del bien.
- **Estrategia 2 — Variables numéricas con nulos:** imputación con la mediana más creación de columnas *flag* (**_ISNAN**). La mediana es robusta ante *outliers*; las *flags* preservan la señal de riesgo asociada a la ausencia del dato para que el modelo pueda aprender ese patrón.
- **Estrategia 3 — Variables categóricas con nulos:** imputación con la categoría '**Unknown**'. Asignar la moda introduciría un sesgo artificial; crear explícitamente una categoría desconocida permite que el modelo trate la ausencia como un patrón propio. Aplicado a **OCCUPATION_TYPE** y **NAME_TYPE_SUITE**.

Al finalizar todo este apartado se puede observar el notebook el mensaje de **total_nulos=0**. De esta forma el dataset queda completamente libre de valores faltantes y listo para el encoding.

6.2 - Codificación de variables (Encoding)

Dado que los algoritmos de Machine Learning operan exclusivamente con valores numéricos, las variables categóricas del dataset se han codificado siguiendo una estrategia híbrida:

1. **Label Encoding** → para las tres variables binarias por naturaleza (**CODE_GENDER**, **FLAG_OWN_CAR** y **FLAG_OWN_REALTY**). Convierte directamente cada categoría en 0 o 1 sin crear columnas adicionales.
2. **One-Hot Encoding** → para el resto de variables nominales, donde no existe un orden jerárquico inherente. Por ejemplo, en **NAME_FAMILY_STATUS** no tiene sentido afirmar que "casado" valga más que "soltero": One-Hot genera una columna binaria por cada categoría posible, evitando que el modelo aprenda relaciones numéricas falsas. El coste es un aumento de dimensionalidad (de 89 a ≈ 240 columnas), asumible dado que la selección de variables del apartado 6.6 lo corregirá después.

6.3 - Ingeniería de características financieras

El *Feature Engineering* busca enseñar al modelo las lógicas de negocio que un analista bancario aplicaría mentalmente al evaluar a un cliente.

Mientras que las soluciones ganadoras de Kaggle se basaron en un *feature engineering* masivo sobre las 7 tablas del dataset, este TFM extrae el máximo poder predictivo de **una sola tabla**, mediante variables agrupadas en cuatro conceptos financieros consolidados.

Antes de crear los ratios, se ha utilizado la función **np.where** para evitar valores infinitos (**inf**): se asigna el valor 0 cuando el denominador es cero, evitando así errores y *warnings* de Pandas.

6.3.1 - Ratios de Capacidad de Pago

Estos ratios responden a la pregunta: "¿Puede este cliente pagar este préstamo con sus ingresos actuales?":

- **PAYMENT_RATE = AMT_ANNUITY/AMT_INCOME_TOTAL**
 - Mide qué porcentaje de los ingresos anuales del cliente se destina al pago de la cuota del préstamo. Un valor alto indica asfixia financiera.
- **CREDIT_TO_INCOME = AMT_CREDIT / AMT_INCOME_TOTAL**
 - Mide cuántos años de ingresos íntegros necesitaría el cliente para pagar el préstamo completo.
- **CREDIT_TERM = AMT_CREDIT / AMT_ANNUITY**

- Aproxima la duración del préstamo en años. Es un indicador del "plazo efectivo" pactado.

6.3.2 - Variables de Estabilidad y Perfil Demográfico

Estas variables transforman los datos crudos en indicadores de estabilidad vital del cliente.

- **AGE_YEARS = $\text{abs}(\text{DAYS_BIRTH}) / 365.25$**
 - Convierte los días negativos en años. Facilita la interpretación humana del modelo.
- **DAYS_EMPLOYED_PERC = $\text{DAYS_EMPLOYED} / \text{DAYS_BIRTH}$**
 - Ratio de antigüedad laboral sobre la vida del cliente. Captura la **estabilidad laboral relativa**: un cliente que ha trabajado el 50 % de su vida es más estable que uno que ha trabajado el 5 %.
- **INCOME_PER_PERSON = $\text{AMT_INCOME_TOTAL} / \text{CNT_FAM_MEMBERS}$**
 - Ingreso por persona en el hogar. El ingreso total es engañoso si no sabemos a cuántas personas alimenta.

6.3.3 - Estrés de Liquidez (*Goods Price Diff*)

Cuando un cliente solicita un préstamo significativamente mayor al precio del bien que dice comprar, indica una **necesidad de liquidez subyacente**: probablemente está utilizando el préstamo para refinanciar otras deudas no declaradas, lo que empíricamente eleva el riesgo de impago.

- **CREDIT_GOODS_DIFF = $\text{AMT_CREDIT} - \text{AMT_GOODS_PRICE}$**
 - Diferencia absoluta entre el préstamo y el precio del bien.
- **CREDIT_GOODS_RATIO = $\text{AMT_CREDIT} / \text{AMT_GOODS_PRICE}$**
 - Ratio relativo. Un valor mayor que 1 indica sobrefinanciación

6.3.4 - Consenso de Fuentes Externas

Las variables **EXT_SOURCE_1**, **EXT_SOURCE_2** y **EXT_SOURCE_3** son *scorings* de burós de crédito externos. Como vimos en el 5.6, son los predictores más potentes del dataset. En lugar de usarlas aisladas, se generan **agregaciones estadísticas** para capturar el "consenso del mercado":

- **EXT_SOURCE_MEAN** — Media de las tres fuentes. Visión consolidada.

- **EXT_SOURCE_MIN** — Mínimo. Penaliza al cliente si alguna fuente lo califica negativamente.
- **EXT_SOURCE_MAX** — Máximo. Premia si al menos una fuente confía en él.
- **EXT_SOURCE_PROD** — Producto. Amplifica el efecto: si las tres son bajas, el producto es muy bajo.

6.3.5 - Variable adicional

- **DISPOSABLE_INCOME = AMT_INCOME_TOTAL - AMT_ANNUITY**
Representa el "colchón financiero" del cliente tras pagar la cuota.

6.4 - División del dataset: prevención del Data Leakage

El **Data Leakage** (literalmente, "fuga de datos") se produce cuando, durante el entrenamiento, el modelo accede a información que no debería conocer en el momento de la predicción real. Es uno de los errores más graves en proyectos de Machine Learning, ya que infla artificialmente las métricas y produce modelos que parecen excelentes en validación pero fracasan en producción.

Una forma intuitiva de entenderlo: es como estudiar para un examen con las mismas preguntas que van a salir. La nota será claramente alta, pero el estudiante no habrá aprendido nada.

La estrategia de partición aplicada para prevenir el Data Leakage es la siguiente:

Hold-out 70/10/20 estratificado.

- **70% Train (215.000 registros):** para entrenar los modelos
- **10% Validation (30.751 registros):** conjunto utilizado para ajustar hiperparámetros, comparar variantes y tomar decisiones técnicas.
- **20% Test (61.502 registros):** conjunto **intocable** hasta la evaluación final, para una medida realista de generalización.

Se descartó K-Fold Cross-Validation porque con 307.511 registros los subconjuntos ya son estadísticamente representativos, y aplicar K-Fold multiplicaría el tiempo de entrenamiento por el número de *folds* sobre cinco modelos distintos.

6.5 - Imputación y escalado (post-split)

Tras crear las variables financieras (algunas generan nuevos nulos al combinar columnas con nulos previos), se aplican dos transformaciones adicionales. Ambas siguen el mismo principio anti-Data Leakage: los parámetros se calculan exclusivamente sobre `X_train` y se aplican con `.transform()` sobre los tres subconjuntos, impidiendo que el modelo acceda indirectamente a información de validación o test

Imputación: `SimpleImputer(strategy='median')`. Se usa la mediana por su robustez ante los *outliers* que abundan en las variables económicas del dataset.

Escalado: `StandardScaler`, que transforma cada variable a media 0 y desviación típica 1 (estandarización Z-score). Sin escalado previo, los algoritmos basados en distancias (**SVM**, **MLP**) darían un peso desproporcionado a variables de gran magnitud como **AMT_INCOME_TOTAL** frente a otras como **EXT_SOURCE_1** (rango 0–1). Aunque **LightGBM** no lo requiere, se aplica de forma uniforme a todos los modelos para garantizar condiciones idénticas de comparación en el Capítulo 4.

6.6 - Selección de variables

Tras el *encoding* y el *feature engineering*, el dataset cuenta con **240 variables**. Trabajar con un número tan elevado de *features* puede generar varios problemas:

- **Maldición de la dimensionalidad:** a mayor número de variables, más datos son necesarios para que el espacio quede densamente poblado.
- **Sobreajuste (*overfitting*):** el modelo puede aprenderse "el ruido" de variables poco informativas.
- **Tiempo de entrenamiento elevado:** especialmente crítico con cinco modelos a entrenar.
- **Pérdida de interpretabilidad:** explicar un modelo con 240 variables es mucho más complicado que explicar uno con 22.

Para resolver estos problemas se aplica la siguiente técnica:

- **SelectFromModel + Random Forest**

Se entrena un primer **RandomForestClassifier** sobre los datos de entrenamiento como mecanismo de evaluación de la importancia de cada variable. Sobre ese modelo se aplica **SelectFromModel** (de Scikit-learn), que conserva automáticamente únicamente aquellas variables cuya importancia supera un umbral por defecto (la importancia media del conjunto).

Justificación: Random Forest ofrece una métrica de importancia (*feature importance*) basada en la reducción de impureza ponderada, ampliamente utilizada en la industria como técnica de selección de variables.




Figura 6.1. Top 22 variables seleccionadas por Random Forest (ordenadas por importancia)

El resultado de todo esto es:

Etapa	Número de Variables
Antes de la Selección	240
Después de la Selección	22
Reducción	91%

Tabla 6.1. Resultado de la selección de variables.

6.7 - Balanceo de clases: SMOTE vs Ponderación

Como se vio en el apartado 5.1, el dataset presenta un fuerte desbalanceo (92 % frente a 8 %). En esta fase se aplican las dos técnicas presentadas en el Marco Teórico —SMOTE y ponderación de clases— para evaluar empíricamente cuál resulta más efectiva.

Técnica 1 — SMOTE (sobremuestreo sintético)

Se utiliza la librería **imbalanced-learn** con el parámetro **sampling_strategy=0.5**, de forma que la clase minoritaria pase a representar el 50 % del tamaño de la mayoritaria. Se descarta una proporción 1.0 (50/50) porque generaría demasiados datos sintéticos y aumentaría el riesgo de introducir ruido en el entrenamiento.

SMOTE se aplica **únicamente sobre el conjunto de entrenamiento**: emplearlo sobre validación o test invalidaría las métricas, ya que introduciría datos sintéticos en una evaluación que debe simular condiciones reales.

Tras aplicar la técnica, la clase minoritaria pasa de unos 17.000 a 98.000 registros.

Técnica 2 — Ponderación nativa de clases

Esta técnica adopta un planteamiento distinto: en lugar de generar datos artificiales, modifica el propio algoritmo para que penalice con mayor severidad los errores cometidos sobre la clase minoritaria. Se implementa mediante **is_unbalance=True** en LightGBM y **class_weight='balanced'** en los modelos de Scikit-learn.

Su ventaja principal es que **no introduce ruido sintético** y mantiene la distribución real de los datos.

7. Capítulo 4: Entrenamiento de evaluación

Una vez preparado el dataset definitivo (22 variables seleccionadas, escaladas y con dos versiones del conjunto de entrenamiento: una balanceada con SMOTE y otra con su distribución original), en este capítulo se entrenan cinco modelos de clasificación binaria pertenecientes a familias algorítmicas distintas. El objetivo es realizar un *benchmark* sistemático que permita identificar el modelo con mejor equilibrio entre capacidad predictiva, detección de impagos y viabilidad para

producción bancaria. Los cinco modelos se evalúan sobre el mismo conjunto de validación (≈ 30.000 registros, 10 % del total), bajo las mismas 22 variables y con umbral inicial de 0,5; el conjunto de test (≈ 61.000 registros) permanece intocado hasta la evaluación final. El **random_state=42** fijado en todos los pasos del *pipeline* garantiza la reproducibilidad completa.

7.1 - Métricas de evaluación

Como se vio en el apartado 5.1, el dataset está fuertemente desbalanceado. En este contexto, la métrica *accuracy* (porcentaje de aciertos) resulta engañosa: un modelo que predijera siempre "pagará" obtendría un 92 % de *accuracy* y sería completamente inútil. Por ello, en problemas de riesgo crediticio se utilizan métricas más sofisticadas, todas ellas derivadas de la **matriz de confusión**:

Tabla 7.1. Estructura de la matriz de confusión aplicada al caso de uso.

	Predicción 0 (paga)	Predicción 1 (No paga)
Real 0 (paga)	TN — Verdadero Negativo	FP — Falso Positivo
Real 1 (No paga)	FN — Falso Negativo	TP — Verdadero Positivo

La interpretación de cada cuadrante en términos de negocio bancario es la siguiente:

- **TN**: el modelo aprueba un buen cliente. El banco gana intereses.
- **TP**: el modelo rechaza a un cliente que no iba a pagar. El banco evita una pérdida.
- **FP**: el modelo rechaza a un cliente que sí habría pagado. El banco pierde un cliente potencial.
- **FN**: el modelo aprueba a un cliente que no va a pagar. El banco asume una pérdida directa.

De todos estos errores, el más costoso es el **FN**, ya que se traduce en una pérdida monetaria real. Por este motivo, el **Recall** (que minimiza los FN) se convierte en la métrica prioritaria en este TFM.

A partir de la matriz de confusión se derivan las siguientes métricas:

- **Accuracy** = $(TP + TN) / \text{Total}$ → no se utiliza como métrica principal por el desbalanceo.

- **Precision** = $TP / (TP + FP)$ → de los clientes etiquetados como morosos, ¿cuántos lo eran realmente?
- **Recall** = $TP / (TP + FN)$ → de todos los morosos reales, ¿cuántos detectó el modelo? Es la **métrica prioritaria** de este TFM.
- **F1-Score** = $2 \cdot (Precision \cdot Recall) / (Precision + Recall)$ → media armónica entre Precision y Recall.

Más allá de estas métricas se encuentra el **AUC-ROC**, la métrica de referencia en la industria y la principal de este trabajo. La curva ROC representa la relación entre la tasa de Verdaderos Positivos (Recall) y la tasa de Falsos Positivos a medida que se modifica el umbral de decisión. El **AUC** (*Area Under the Curve*) es el área bajo dicha curva y toma valores entre 0,5 (modelo aleatorio) y 1,0 (modelo perfecto).

El AUC se considera el estándar internacional para evaluar modelos de scoring crediticio porque es **independiente del umbral de decisión** y mide la capacidad intrínseca del modelo para distinguir entre las dos clases.

En este TFM se utilizan las cinco métricas anteriores, pero el ranking final se establece en función del **AUC-ROC** y, en caso de empate, del **Recall**, dado que el objetivo principal es maximizar la detección de impagos.

7.2 - Random Forest (con SMOTE)

Random Forest, presentado teóricamente en el apartado 3.5.1, se ha entrenado en primer lugar como modelo de referencia (*baseline*) sobre el conjunto sobremuestreado con SMOTE.

Tabla 7.2. Hiperparámetros del modelo Random Forest.

Hiperparámetro	Valor	Justificación
n_estimators	200	Número de árboles, equilibrio entre rendimiento y coste computacional.
max_depth	10	Profundidad limitada para evitar sobreajuste.
min_samples_leaf	5	Suaviza el modelo y mejora la generalización.
class_weight	'balanced'	Refuerzo adicional al SMOTE para el desbalanceo residual.

random_state	42	Garantiza reproducibilidad.
--------------	----	-----------------------------

Resultados: AUC = **0,7236**, Recall = **0,59**, Precision = **0,16**.




Figura 7.1. Matriz de confusión del modelo Random Forest sobre el conjunto de validación

La matriz de confusión, ya presentada teóricamente en el apartado 7.1, permite leer en términos de negocio los aciertos y errores del modelo sobre los 30.751 registros del conjunto de validación:

- **20.849 TN:** clientes que iban a pagar y el modelo aprueba correctamente.
- **1.460 TP:** clientes que iban a impagar y el modelo detecta correctamente.
- **7.419 FP:** clientes que sí habrían pagado pero el modelo rechaza erróneamente.
- **1.023 FN:** clientes morosos que el modelo aprueba erróneamente, generando pérdida directa para el banco.

De los **2.483 clientes que realmente iban a impagar**, el modelo detecta a **1.460** (Recall = 59%), evitando así una proporción significativa de las pérdidas potenciales. Sin embargo, esta detección tiene un coste claro: para "cazar" a esos morosos, el modelo etiqueta erróneamente como riesgo a **7.419 clientes que eran buenos pagadores** (Falsos Positivos), lo que se traduce en una baja Precision del 16%

Este equilibrio (alto Recall a costa de baja Precisión) es coherente con la **prioridad de negocio** asumida en el TFM: en banca, perder un cliente potencial (FP) es costoso, pero asumir una pérdida directa por impago (FN) lo es aún más.

Aun así, el AUC de 0,72 establece únicamente la **línea base** del *benchmark*, dejando margen claro de mejora para los modelos siguientes.

7.3 - LightGBM (con SMOTE)

LightGBM, presentado en el apartado 3.5.2, es un algoritmo de *Gradient Boosting* considerado el estado del arte en datos tabulares. Se prueba aquí sobre el mismo conjunto sobremuestreado con SMOTE para evaluar si supera al *baseline* de Random Forest en igualdad de condiciones.

Tabla 7.3. Hiperparámetros del modelo LightGBM (SMOTE).

Hiperparámetro	Valor
objective	'binary'
metric	'auc'
boosting_type	'gbdt'
is_unbalance	False
num_leaves	31
learning_rate	0,05
feature_fraction	0,9

Se utiliza adicionalmente *Early Stopping* (**stopping_rounds=50**) para detener el entrenamiento si la métrica de validación no mejora durante 50 rondas consecutivas, lo que previene el sobreajuste.

Resultados: AUC = **0,7208** , Recall = **0,22** , Precision = **0,24**.

Llama particularmente la atención el desplome del Recall (del 59 % del Random Forest al 22 %): el modelo ha aprendido a ser mucho más conservador a la hora de etiquetar a un cliente como moroso, lo que en banca implica perder la capacidad de detectar a la mayoría de los impagos.

Sorprendentemente, **LightGBM con SMOTE no supera a Random Forest**. La explicación es algorítmica: los modelos de *Gradient Boosting* son muy sensibles a la calidad del dato de entrenamiento, y los ejemplos sintéticos generados por

SMOTE introducen ruido que perjudica el aprendizaje secuencial. Esta observación motiva directamente a la siguiente prueba.

7.4 - LightGBM con Ponderación Nativa (Sin SMOTE)

Tras el resultado anterior, se entrena **LightGBM** sobre los datos originales (sin SMOTE) y se activa su parámetro nativo **is_unbalance=True**, que ajusta internamente los pesos de las clases. Esta configuración mantiene la distribución real de los datos y delega la gestión del desbalanceo en el mecanismo matemático interno del propio algoritmo.

Tabla 7.4. Hiperparámetros del modelo LightGBM (Ponderado).

Hiperparámetro	Valor	Cambio respecto al anterior
is_unbalance	True	Activado (cambio clave)

Resultados: AUC = **0,756**, Recall (Clase 1) = **0,68**, Precision = **0,16**.

Tres conclusiones clave se extraen de estos resultados:

- **Salto significativo en AUC:** se pasa de 0,7236 (Random Forest) y 0,7208 (LightGBM con SMOTE) a **0,75**. En el ámbito del scoring crediticio, una mejora absoluta de +0,03 puntos absolutos de AUC es muy relevante.
- **Recall del 68%:** el modelo detecta casi **7 de cada 10 impagos**, prácticamente 10 puntos porcentuales por encima del *baseline* del Random Forest. En términos de negocio, esto se traduce directamente en pérdidas evitadas para la entidad financiera.
- **Control del sobreajuste:** la diferencia entre el AUC en entrenamiento (0,80) y en validación (0,76) es de solo 0,04 puntos, lo que indica que el modelo generaliza correctamente y no muestra signos preocupantes de *overfitting*.

Este resultado confirma empíricamente lo anticipado en el Marco Teórico: para algoritmos de *Gradient Boosting*, **la ponderación nativa es preferible al sobremuestreo sintético**, ya que mantiene la distribución real de los datos y aprovecha el mecanismo matemático interno del propio algoritmo.

7.5 - SVM - LinearSVC

SVM, presentado en el apartado 3.5.3, se ha entrenado en su variante **lineal** (**LinearSVC**). El uso de un kernel radial habría sido inviable con más de 300.000 registros debido a su complejidad computacional cuadrática, mientras que LinearSVC escala linealmente.

Tabla 7.5. *Hiperparámetros del modelo LinearSVC.*

Hiperparámetro	Valor
class_weight	'balanced'
max_iter	2000
random_state	42

Resultados: AUC = **0,73**.

LinearSVC obtiene un resultado competitivo, incluso superior al Random Forest, lo que confirma que la ingeniería de variables aplicada en el Capítulo 3 es lo bastante potente como para que incluso un modelo lineal alcance un buen rendimiento. No obstante, queda claramente por debajo del LightGBM ponderado: SVM no captura interacciones no lineales entre variables y no devuelve probabilidades calibradas de forma directa, lo que dificulta su uso en producción.

7.6 - Red Neuronal MLP

El Perceptrón Multicapa (MLP), presentado en el apartado 3.5.4, se incluye en el benchmark para verificar empíricamente si un enfoque basado en *Deep Learning* podría superar al *Gradient Boosting* en este caso de uso.

Tabla 7.6. *Hiperparámetros del modelo MLP.*

Hiperparámetro	Valor
hidden_layer_sizes	(64, 32)
activation	'relu'
solver	'adam'

max_iter	100
early_stopping	True

Dado que el MLP de Scikit-learn no incorpora un parámetro nativo equivalente a **class_weight**, se entrena con el conjunto sobremuestreado con SMOTE.

Resultados: AUC = **0,69**.

El MLP obtiene el peor resultado del *benchmark*. Lejos de ser sorprendente, este resultado **confirma lo previsto en el Marco Teórico** (Shwartz-Ziv & Armon, 2022): en datos tabulares, los algoritmos basados en árboles —y especialmente *Gradient Boosting*— superan consistentemente al *Deep Learning*. Las redes neuronales destacan en problemas no estructurados (imágenes, texto, audio), pero pierden ventaja en dominios tabulares de baja dimensionalidad como el scoring crediticio. A esto se suman dos inconvenientes prácticos relevantes para el contexto bancario: mayor coste computacional y, sobre todo, **menor interpretabilidad**.

Tras entrenar y evaluar los cinco modelos sobre el conjunto de validación, se dispone ya de toda la información necesaria para tomar una decisión informada. El siguiente capítulo consolida los resultados en una tabla comparativa, analiza el impacto del umbral de decisión sobre el negocio y justifica formalmente la elección del modelo ganador.

8. Capítulo 5: Elección del modelo

En el capítulo anterior se entrenaron cinco modelos de clasificación binaria pertenecientes a familias algorítmicas distintas. Cada uno fue evaluado de forma aislada sobre el conjunto de validación. Este capítulo aborda la fase de síntesis: consolidar los resultados en una visión comparativa, analizar el comportamiento del modelo ganador bajo distintos umbrales de decisión y justificar formalmente su elección atendiendo no solo a las métricas estadísticas, sino también a criterios de viabilidad de negocio y cumplimiento normativo

8.1 - Tabla comparativa del benchmark

Tabla 8.1. Tabla comparativa del benchmark

Modelo	Familia	Desbalanceo	AUC	Recall	Precision	F1
Random Forest	Bagging	SMOTE	0,7236	0,59	0,16	0,26
LightGBM	Gradient Boosting	SMOTE	0,7208	0,207	0,231	0,22
LightGBM Ponderado	Gradient Boosting	Nativa	0,7563	0,68	0,17	0,27
SVM(LinearSVC)	Modelos Geométricos	Ponderado	0,7325	–	–	–
MLP	Deep Learning	SMOTE	0,6970	–	–	–

Nota: Recall, Precision y F1 se reportan únicamente para los modelos que devuelven predicciones binarias directas con umbral 0,5. Para SVM (LinearSVC) y MLP, ambos descartados antes de la fase de evaluación detallada, solo se reporta el AUC como métrica de comparación

El ganador: **LightGBM Ponderado** lidera simultáneamente en AUC (+2,4 puntos sobre el segundo) y en Recall (+9 puntos sobre Random Forest). En problemas reales esta doble dominancia es poco habitual: lo normal es que un modelo gane en AUC y otro en Recall. Aquí no hay duda razonable

SVM lineal queda en segundo lugar de AUC (**0,73**), por encima incluso del Random Forest. Esto valida empíricamente la calidad del Feature Engineering del Capítulo 3: cuando las variables capturan bien la lógica de negocio, incluso un modelo lineal alcanza un rendimiento competitivo. Sin embargo, su carencia de probabilidades calibradas y la imposibilidad de aplicar SHAP de forma directa lo descartan para producción bancaria.

El último puesto de la red neuronal no es accidental, sino que confirma lo previsto en el Marco Teórico (referencia a Shwartz-Ziv & Armon, 2022): en datos tabulares de baja dimensionalidad, el Gradient Boosting supera consistentemente al Deep Learning.

El comportamiento divergente del LightGBM con SMOTE vs ponderación nativa (Recall del 22 % vs 68%) merece una mención explícita. No es un detalle anecdótico: contradice una intuición muy extendida en la comunidad de ciencia

de datos según la cual SMOTE siempre mejora el rendimiento en datasets desbalanceados.

8.2 - Análisis del umbral de decisión

Al entrenar y probar un modelo de clasificación no devuelve directamente un “sí” o un “no”, sino una probabilidad entre 0 y 1, por ejemplo puede poner que X cliente tiene una probabilidad de 0,38 de no pagar. El umbral es la línea de corte que convierte esa probabilidad en una decisión binaria. Por convención, el valor por defecto es 0,5, pero este no es una constante fija: en banca puede ajustarse según la prioridad del negocio.

Una forma de observar todo esto es viéndolo como un detector de metales dentro de un aeropuerto. Si lo configuras muy sensible (umbral bajo), detectarás muchas cosas inofensivas como peligrosas, pero rara vez se te escapará un cuchillo (alto Recall). Si lo configuras poco sensible (umbral alto), apenas molestarás a los viajeros, pero podrías dejar pasar objetos peligrosos (bajo Recall). El umbral hace referencia a la tolerancia al riesgo.

Este umbral es altamente relevante en banca, debido a que cada entidad financiera tiene una función de coste distinta. Un banco con apetito de riesgo alto puede tolerar más FN; un banco conservador prefiere FP. El umbral es la palanca operativa más directa para alinear el modelo con la estrategia de negocio sin necesidad de reentrenar.

Tabla 8.2. Análisis de sensibilidad del umbral de decisión sobre el modelo LightGBM Ponderado

Umbral	Recall	Precision	TP	FP	Interpretación de Negocio
0,40	0,793	0,138	1.968	12.259	Muy agresivo: detecta casi 8 de cada 10 morosos, pero a costa de rechazar 12k buenos pagadores.
0,50	0,675	0,168	1.675	8.305	Configuración por defecto. Equilibrio del modelo ganador.
0,60	0,534	0,206	1.327	5.122	Más estricto al etiquetar como moroso: menos rechazos injustos, pero deja escapar más

Umbral	Recall	Precision	TP	FP	Interpretación de Negocio
0,40	0,793	0,138	1.968	12.259	Muy agresivo: detecta casi 8 de cada 10 morosos, pero a costa de rechazar 12k buenos pagadores.
					impagos.
0,70	0,365	0,262	906	2.550	Conservador: solo etiqueta como moroso a quien tiene probabilidad muy alta. Pierde casi 2 de cada 3 morosos reales.




Figura 8.1. Curvas de Recall y Precision frente al umbral de decisión. Se observa el clásico trade-off entre ambas métricas

A medida que el umbral aumenta, el Recall cae con fuerza (del 79 % al 37 % entre 0,40 y 0,70) mientras que la **Precision** sube de forma mucho más moderada (del 14% al 26%). Este patrón asimétrico es característico de los problemas desbalanceados: como la clase mayoritaria (buenos pagadores) representa más del 92 % del dataset, exigir más al modelo para etiquetar a alguien como moroso lo vuelve cada vez más selectivo, pero también deja escapar a la mayoría de los impagos reales.

Dentro de este proyecto, se mantiene el umbral por defecto de 0,5 por dos motivos:

1. El negocio bancario penaliza más los FN (impagos no detectados) que los FP (rechazos injustos), por lo que un Recall del 68% se considera el punto de equilibrio adecuado.
2. En un despliegue real, este umbral sería un hiperparámetro de negocio configurable, ajustable por el equipo de riesgo en función del ciclo económico, apetito de riesgo y la rentabilidad por cliente.

8.3 - Justificación del modelo ganador

La elección del modelo ganador no puede sustentarse en un único criterio. Una decisión rigurosa, especialmente en un sector tan regulado como el bancario, debe atender simultáneamente al rendimiento estadístico, a la viabilidad operativa, al cumplimiento normativo y a la eficiencia computacional. A continuación se presentan los cuatro criterios bajo los cuales se justifica formalmente la elección del LightGBM Ponderado

1. Criterio 1 - Rendimiento predictivo superior

- a. AUC de 0,756 (vs 0,7325 del segundo mejor, SVM): mejora absoluta de **+2,4 puntos**. En scoring crediticio, mejoras de ese orden son competitivas a nivel sectorial.
- b. Recall del 68%: detecta casi 7 de cada 10 impagos. Es la métrica que más impacta en pérdidas evitadas.
- c. Control del sobreajuste: la diferencia entre AUC en entrenamiento (~0,80) y validación (~0,76) es de alrededor 0,05 puntos , evidencia clara de buena generalización
- d. Comparación con SOTA: las soluciones ganadoras de Kaggle alcanzaron AUC ~0,80 usando las 7 tablas. Con una sola tabla, este TFM alcanza 0,756. **Conserva el 94,5 % del rendimiento de SOTA reduciendo enormemente la complejidad.**

2. Criterio 2 - Viabilidad de negocio:

- a. LightGBM permite probabilidades calibradas (a diferencia de LinearSVC): imprescindible para el motor de decisión bancario.
- b. Permite ajuste de umbral operativo (como se demostró en 8.2): herramienta clave para que el departamento de riesgos alinee el modelo con la estrategia.

- c. El parámetro **is_unbalance=True** mantiene la distribución real de los datos sin recurrir a datos sintéticos, lo que en una auditoría bancaria es defensible con mayor facilidad que un modelo entrenado sobre SMOTE

3. Criterio 3 - Cumplimiento normativo

- a. Compatible con SHAP a través de **TreeExplainer**, lo que permite cumplir con el artículo 22 del GDPR (derecho a la explicación) y con la clasificación de "alto riesgo" del EU AI Act 2024.
- b. Trazabilidad completa: cada predicción puede descomponerse en la contribución de cada variable.
- c. Esta dimensión se desarrollará en profundidad en el siguiente capítulo, donde se aplica SHAP al modelo ganador.

4. Criterio 4 - Eficiencia computacional

- a. LightGBM es el algoritmo de Gradient Boosting más rápido del estado del arte (Ke et al., 2017): puede entrenarse en minutos sobre los 215.000 registros del conjunto de entrenamiento.
- b. En producción, la inferencia es prácticamente instantánea: una entidad bancaria puede integrarlo en su pipeline de decisión sin penalización de latencia.

Por lo que, LightGBM Ponderado se selecciona como modelo final del TFM. Sin embargo, su elección no concluye el análisis: en banca, ningún modelo puede operar como una caja negra. El siguiente capítulo aborda precisamente la dimensión que hace de este modelo no solo el más preciso, sino también el más viable en producción: su explicabilidad mediante técnicas de Inteligencia Artificial Explicable (XAI) con SHAP.

9. Capítulo 6: Explicabilidad del modelo (XAI con SHAP)

9.1 - Por qué la explicabilidad es obligatoria en banca


Como se estableció en el Marco Teórico (apartado 3.6) y en el marco normativo (apartado 4.2), la explicabilidad no es una opción técnica sino una obligación legal en el contexto bancario europeo: el GDPR (Art. 22), los Acuerdos de Basilea III/IV (Comité de Supervisión Bancaria de Basilea, 2017) y el EU AI Act

2024 exigen que cualquier decisión automatizada sea interpretable y trazable. Este capítulo aplica técnicas de Inteligencia Artificial Explicable (XAI) mediante SHAP sobre el modelo ganador (LightGBM Ponderado) para cumplir ese requisito, tanto desde una perspectiva global del modelo como a nivel de un cliente individual.

9.2 - Análisis global: variables más influyentes

Para el análisis de explicabilidad se ha utilizado **TreeExplainer** de la librería SHAP, optimizado para modelos basados en árboles de decisión. Los valores SHAP se calculan sobre el conjunto de validación (30.000 clientes), lo que garantiza que la interpretación se realiza sobre datos nunca vistos durante el entrenamiento.

Figura 9.1. Importancia global de las variables del modelo LightGBM Ponderado según valores SHAP (Beeswarm plot, conjunto de validación).



El gráfico muestra en el eje vertical las variables ordenadas por importancia global, y en el eje horizontal el valor SHAP de cada observación: los puntos a la derecha del cero (en rojo) aumentan el riesgo de impago, mientras que los puntos a la izquierda (en azul) lo reducen. El color de cada punto indica el valor de la variable — rojo para valores altos, azul para bajos. Del análisis se extraen tres hallazgos principales:

1. **Dominio de las variables EXT_SOURCE.** Las variables **EXT_SOURCE_MEAN**, **EXT_SOURCE_PROD**, **EXT_SOURCE_3**, **EXT_SOURCE_1** y **EXT_SOURCE_MAX** ocupan varias de las primeras posiciones. Esto confirma empíricamente que el *Feature Engineering* del apartado 6.3.4 fue acertado: agregar las tres fuentes externas en lugar de usarlas de forma aislada captura mejor el consenso de los burós de crédito. Los puntos azules a la izquierda del eje indican que puntuaciones altas en estas fuentes reducen significativamente la probabilidad de impago, mientras que los puntos rojos a la derecha muestran el efecto contrario cuando los *scorings* son bajos.
2. **Relevancia de CREDIT_TERM.** La segunda variable más importante es **CREDIT_TERM**, el plazo efectivo del préstamo. Plazos cortos combinados con cuotas elevadas relativas al importe total se asocian con mayor riesgo, lo que tiene una interpretación directa en términos de negocio: cuanto más comprimido está el esfuerzo de pago, mayor es la probabilidad de impago.
3. **Variables de estrés financiero y perfil demográfico.** **CREDIT_GOODS_RATIO** y **CREDIT_GOODS_DIFF** muestran valores SHAP positivos cuando son altos: la sobrefinanciación respecto al precio del bien es señal de necesidad de liquidez subyacente y se asocia con mayor riesgo. En sentido contrario, **DAYS_EMPLOYED** y **AGE_YEARS** presentan valores SHAP negativos para clientes con mayor antigüedad laboral y mayor edad, coherentes con la lógica bancaria de que la estabilidad laboral y la madurez actúan como factores protectores.


El análisis global es consistente con la selección de variables del apartado 6.6, donde la Figura 6.1 mostraba un ranking muy similar basado en importancias de

Random Forest. Que dos métodos de interpretación distintos señalen las mismas variables como relevantes refuerza la robustez de los resultados.

9.3 - Análisis individual: un caso real

El análisis global describe el comportamiento del modelo en promedio. Sin embargo, la regulación bancaria exige explicaciones a nivel de cliente individual: si se deniega un préstamo, el solicitante tiene derecho a conocer los motivos concretos. Para ilustrar esta capacidad se analiza el cliente del conjunto de validación con mayor probabilidad de impago predicha por el modelo.

Figura 9.2. Análisis SHAP individual (Waterfall plot) para el cliente con mayor probabilidad de impago del conjunto de validación.



El gráfico se lee de abajo a arriba. El punto de partida es $E[f(X)] = -0,512$, el valor medio de salida del modelo sobre toda la población de validación. Cada barra representa la contribución de una variable a la predicción final: las barras rojas empujan la predicción hacia la derecha (aumentan el riesgo) y las barras azules la desplazan hacia la izquierda (lo reducen). La suma de todas las contribuciones lleva hasta $f(x) = 2,812$, el valor de salida del modelo para este cliente concreto, que corresponde a una probabilidad de impago de aproximadamente el 94 %.

Lo que más me ha llamado la atención es que **todas las contribuciones son positivas**: no existe ninguna variable que actúe como factor protector, lo que convierte a este cliente en un perfil de riesgo extremo.

El factor de mayor impacto es **EXT_SOURCE_MEAN** con una contribución de **+0,96**, el valor más alto del gráfico. El valor escalado de esta variable para el cliente es $-2,73$, es decir, su puntuación media de los burós externos se sitúa a casi tres desviaciones estándar por debajo de la media de la población, indicando que los servicios de información crediticia externa le asignan una solvencia muy baja de forma consistente. Le siguen **EXT_SOURCE_PROD** (+0,45) y **EXT_SOURCE_3** (+0,22), que confirman que la señal negativa de las fuentes externas es coherente entre sí: los tres burós coinciden en evaluar a este cliente como de alto riesgo.

La variable **CREDIT_TERM** contribuye con **+0,38** a pesar de tener un valor ligeramente por debajo de la media ($-0,143$). Esto indica que el plazo efectivo del préstamo, combinado con el nivel de ingresos del cliente, genera una carga de cuota relativa que el modelo asocia con dificultades de pago. Finalmente, **CREDIT_GOODS_RATIO** = 2,388 desviaciones estándar por encima de la media (+0,29 de contribución SHAP) revela una sobrefinanciación clara: el importe del préstamo solicitado supera significativamente el precio del bien financiado, señal frecuente de necesidad de liquidez subyacente que, como se estableció en el apartado 6.3.3, se asocia empíricamente con mayor riesgo de impago.

En un contexto bancario real, esta descomposición SHAP sería exactamente el informe que el gestor de riesgos entregaría al cliente para justificar la denegación, cumpliendo con el derecho a explicación del artículo 22 del GDPR y con los requisitos de trazabilidad del Reglamento UE 2024/1689.

El análisis SHAP confirma que el modelo no solo es preciso, sino interpretable: sus decisiones reproducen la lógica que un analista bancario experto aplicaría manualmente. Esta alineación entre el comportamiento del algoritmo y el conocimiento del dominio es la condición necesaria para que un modelo de Machine Learning sea viable en producción en el sector financiero europeo. En los capítulos siguientes se describe cómo el modelo ha sido serializado y publicado para facilitar su uso real.

10. Capítulo 7: Exportación del modelo

Una vez seleccionado y validado el modelo ganador, el siguiente paso es serializarlo: convertirlo en archivos persistentes que puedan cargarse y ejecutarse en cualquier entorno sin necesidad de reentrenar. Esta fase, cierra el ciclo de desarrollo local y prepara el modelo para su despliegue.

La serialización se realiza con la librería **joblib**, estándar en el ecosistema Python por su eficiencia con objetos numéricos de gran tamaño como los árboles internos de **LightGBM**. El proceso genera tres artefactos independientes, cada uno con un propósito específico e insustituible:

Tabla 10.1. Artefactos exportados del modelo final.

Archivo	Contenido	Por qué es necesario
model_lgbm_final.pkl	Modelo LightGBM Ponderado entrenado	Contiene los pesos, árboles y parámetros aprendidos durante el entrenamiento
scaler.pkl	Objeto StandardScaler ajustado sobre X_train	Cualquier dato nuevo debe escalarse con los mismos parámetros (media y desviación típica) que el modelo vio durante el entrenamiento; usar un escalador diferente invalidaría las predicciones
features_list.pkl	Lista exacta de las 22 variables en el orden correcto	El modelo es sensible al orden y nombre de las columnas; esta lista garantiza que los datos de entrada se alineen correctamente con lo que el modelo espera

Los tres ficheros funcionan como una **unidad inseparable**: cargar el modelo sin el escalador correcto produce predicciones erróneas, y cargar el modelo sin la lista de variables genera errores de dimensionalidad. Este principio justifica versionar los tres artefactos conjuntamente en el repositorio de Hugging Face, tal como se describe en el capítulo siguiente.

11. Capítulo 8: Despliegue en Hugging Face

Con los tres artefactos generados localmente, el último paso del proyecto es publicarlos en un repositorio público para garantizar la reproducibilidad, la

trazabilidad y el acceso abierto a la comunidad académica y profesional. Como se describió en el Marco Teórico (apartado 3.7), Hugging Face es la plataforma de referencia para esta finalidad en el ecosistema de IA abierta.

El repositorio público del modelo se encuentra en:

[IzanMoya/Credit-Scoring-Risk-Model-TFM](#)

El repositorio contiene, además de los tres artefactos del modelo, una **Model Card**: ficha estandarizada que documenta el propósito del modelo, los datos de entrenamiento, las métricas obtenidas, las limitaciones conocidas y la licencia. Las Model Cards, introducidas por Mitchell et al. (2019), son el estándar de transparencia adoptado por la industria y responden directamente a las exigencias de documentación técnica del Reglamento UE 2024/1689.

El despliegue en Hugging Face aporta tres garantías concretas para el contexto bancario y académico:

Reproducibilidad completa: cualquier investigador puede descargar los tres artefactos y obtener exactamente las mismas predicciones que las reportadas en este TFM, verificando así la integridad del trabajo.

Trazabilidad: el repositorio utiliza versionado Git LFS, lo que significa que cada actualización del modelo queda registrada con su historial completo de cambios. Esto cumple directamente los requisitos de trazabilidad de Basilea IV y el EU AI Act, que exigen que los modelos de alto riesgo sean auditables.

Acceso abierto: el repositorio es público, lo que permite la auditoría externa del modelo — un requisito implícito de la clasificación de "alto riesgo" del EU AI Act y un principio de ciencia reproducible cada vez más exigido en el ámbito académico.

Como línea de trabajo futura, el repositorio puede ampliarse con un *Space* de Hugging Face — una demo interactiva construida con Streamlit o Gradio — que permita introducir los datos de un cliente y obtener en tiempo real su probabilidad de impago junto con la explicación SHAP individual correspondiente, llevando el TFM de la publicación académica a la demostración funcional.

Con la publicación en Hugging Face se completa el ciclo íntegro del proyecto: desde la exploración de los datos hasta el despliegue de un modelo interpretable, trazable y accesible, alineado con los requisitos normativos del sector bancario europeo. Las conclusiones del trabajo se recogen en el capítulo siguiente.

12. Conclusiones y líneas futuras de trabajo

Este TFM ha sido mi primer contacto real con un proyecto de Machine Learning completo: desde entender un dataset complejo hasta desplegar un modelo en producción. Ha habido momentos en los que no entendía por qué un modelo daba peores resultados al añadirle más datos sintéticos o por qué dos métricas que parecían medir lo mismo apuntaban en direcciones opuestas. Resolver esas dudas, investigando, probando y equivocándome, ha sido la parte más valiosa del proceso.

A nivel técnico, he tenido que profundizar en áreas que desconocía o que solo conocía superficialmente: el tratamiento de datasets desbalanceados, la lógica detrás del Gradient Boosting, el funcionamiento de SHAP y su conexión con la teoría de juegos, o los requisitos normativos concretos que condicionan el uso de IA en banca. Cada uno de esos bloques requirió investigación propia más allá de los contenidos del máster.

La conclusión técnica más importante que me llevo no es el algoritmo elegido, sino algo más general: que la calidad del trabajo previo al modelo (limpiar bien los datos, construir variables con lógica de negocio, evitar fugas de información) importa más que el modelo en sí. Y que la intuición a veces falla: SMOTE empeoró los resultados donde se esperaba que los mejorara.

En cuanto al resultado final, el modelo alcanza un rendimiento competitivo trabajando únicamente con la tabla principal del dataset, lo que confirma que la simplicidad bien ejecutada puede ser tan válida como la complejidad. La capacidad de explicar cada decisión del modelo —variable por variable— no es solo un requisito normativo, sino algo que da sentido real a todo el trabajo: un modelo que no se puede justificar no sirve en producción.

Líneas futuras de trabajo

Los resultados obtenidos abren varias direcciones de mejora y extensión:

La incorporación de las tablas satélite del dataset mediante agregaciones temporales permitiría aproximar el rendimiento de las soluciones ganadoras de Kaggle, manteniendo el enfoque de interpretabilidad.

La optimización bayesiana de hiperparámetros con herramientas como Optuna permitiría explorar el espacio de configuración de LightGBM de forma sistemática y sin el coste de una búsqueda exhaustiva.

El despliegue de una demo interactiva en Hugging Face Spaces, construida con Streamlit o Gradio, convertiría el trabajo en una herramienta funcional: cualquier usuario podría introducir los datos de un cliente y obtener en tiempo real su probabilidad de impago junto con la explicación SHAP correspondiente.

Por último, la validación del modelo con datos más recientes que los de 2018 permitiría evaluar la estabilidad de las variables ante cambios en el perfil de los solicitantes, un requisito clave en producción continua.

13. Bibliografía

Anderson, R. (2007). *The credit scoring toolkit: Theory and practice for retail credit risk management and decision automation*. Oxford University Press.

Banco Central Europeo. (2023). *Estadísticas sobre préstamos dudosos (NPL) en la zona euro*. Banco Central Europeo.

<https://www.bankingsupervision.europa.eu/banking/npe/html/index.en.html>

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.

<https://doi.org/10.1023/A:1010933404324>

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321–357. <https://doi.org/10.1613/jair.953>

Comité de Supervisión Bancaria de Basilea. (2017). *Basilea III: Finalización de las reformas poscrisis*. Banco de Pagos Internacionales.

https://www.bis.org/bcbs/publ/d424_es.htm

Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297. <https://doi.org/10.1007/BF00994018>

He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9), 1263–1284. <https://doi.org/10.1109/TKDE.2008.239>

Home Credit Group, 2018. <https://www.kaggle.com/c/home-credit-default-risk>

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 3146–3154.

Kuhn, M., & Johnson, K. (2019). *Feature engineering and selection: A practical approach for predictive models*. CRC Press. <https://doi.org/10.1201/9781315108230>

Little, R. J. A., & Rubin, D. B. (2019). *Statistical analysis with missing data* (3.^a ed.). Wiley. <https://doi.org/10.1002/9781119482260>

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 4765–4774.

Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., & Gebru, T. (2019). Model cards for model reporting. *Proceedings of the Conference on Fairness, Accountability, and Transparency (FAT*)*, 220–229. <https://doi.org/10.1145/3287560.3287596>

Molnar, C. (2022). *Interpretable machine learning: A guide for making black box models explainable* (2.^a ed.). <https://christophm.github.io/interpretable-ml-book/>

Ng, A. (2014). *Notas de curso: CS229 Machine Learning*. Stanford University. <https://cs229.stanford.edu/>

Reglamento (UE) 2016/679 del Parlamento Europeo y del Consejo, de 27 de abril de 2016, relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales y a la libre circulación de estos datos. *Diario*

Oficial de la Unión Europea, L 119, 1–88.

<https://eur-lex.europa.eu/legal-content/ES/TXT/?uri=CELEX:32016R0679>

Reglamento (UE) 2024/1689 del Parlamento Europeo y del Consejo, de 13 de junio de 2024, por el que se establecen normas armonizadas en materia de inteligencia artificial (Ley de Inteligencia Artificial). *Diario Oficial de la Unión Europea*, L 2024/1689.

<https://eur-lex.europa.eu/legal-content/ES/TXT/?uri=CELEX:32024R1689>

Shwartz-Ziv, R., & Armon, A. (2022). Tabular data: Deep learning is not all you need. *Information Fusion*, 81, 84–90. <https://doi.org/10.1016/j.inffus.2021.11.011>

Thomas, L. C. (2009). *Consumer credit models: Pricing, profit and portfolios*. Oxford University Press.

Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.